

TECH CHALLENGE · FASE 3

Predição e Inteligência Analítica para Alfabetização no Brasil

Da camada Gold aos modelos: quem tende a não ser alfabetizado, onde e por quê

Guilherme Cosme

RM 372204 · Turma 1IAST · MBA AI Scientist · FIAP / POSTECH

 github.com/guillecosome/fiap-ai-scientist-tech-challenge-fase-03

Vídeo executivo (5 min): (link do vídeo)

O problema: antecipar, não só medir

O Indicador Criança Alfabetizada diz, a cada ano, quantas crianças do 2º ano leem e escrevem no nível esperado. Ele mostra onde estamos.

Mas a gestão precisa de outra coisa: saber com antecedência quais municípios tendem a ficar aquém da meta, quais fatores pesam e onde o esforço rende mais.

Esta fase transforma a camada Gold da Fase 2, agora com dado real do Inep e do IBGE, em modelos que respondem a essas perguntas.

56% → 66%

crianças alfabetizadas no 2º ano, 2023 a 2025
(Brasil, rede pública)

80%

meta nacional para 2030, com metas anuais por município

743

pontos na escala Saeb: o corte que define uma criança alfabetizada

Da Gold da Fase 2 ao dado real

1

Indicador e metas

Inep: resultado por município
2023 a 2025 e metas anuais
até 2030

2

Microdados por aluno

4,3 milhões de alunos
avaliados em 2024 e 2025,
com rede, escola e
proficiência

3

Contexto educacional

Censo Escolar (docentes,
turmas, distorção),
rendimento, IDEB 2005 a
2025, INSE

4


Território e renda

IBGE: população, densidade,
PIB e composição da
economia

Mesmo contrato de esquema da Fase 2, tabelas recompostas com as fontes públicas e uma tabela nova no grão de aluno. Nenhuma fonte exige credencial; downloads conferidos por hash.

Regra que evita vazamento: para prever o ano t só entram variáveis conhecidas antes da prova (Censo Escolar de t , rendimento e IDEB de $t-1$, resultado de $t-1$, meta de t).

Três achados que moldaram os modelos



A UF explica um terço da variação

e a região quase nada: Ceará e Bahia são vizinhos e opostos. Gestão estadual e instrumento de prova pesam.

Fluxo escolar pesa mais que renda

abandono, reprovação e distorção idade-série têm correlação três vezes maior que INSE e PIB per capita.

85% da variação é dentro da escola

o modelo do aluno só enxerga o contexto; serve para triagem de redes, não para rotular crianças.

Como os modelos foram construídos

1

Preprocessamento integrado

imputação pela mediana, log nas variáveis de porte e renda, escalonamento e one-hot, tudo dentro do pipeline e ajustado só no treino

2

Validação por município

folds que separam municípios inteiros; busca aleatória de hiperparâmetros em logística, random forest e gradient boosting

3

Teste temporal




treino em 2024, teste em 2025 aberto uma única vez; curvas de aprendizado e ablação por bloco de variáveis

4

Ponto de operação

limiar escolhido pela política: encontrar pelo menos 70% dos casos de não alfabetização

Prever se o aluno será alfabetizado



0.65


AUC-ROC no teste de 2025 (validação 2024: 0.66)

69%

das crianças não alfabetizadas de 2025 identificadas no ponto de operação

Sem dado individual do aluno, o teto é o contexto. O modelo ordena bem o risco entre escolas e municípios e a ordem se manteve no ano seguinte.

Quem tende a não atingir a meta: a lição do alvo



Classificador direto

AUC 0.81 em 2024 e 0.60 em 2025: aprendeu a regra da meta de 2024, que mudou.


Regressão do nível + meta

AUC do risco 0.77 em 2025; ordem dos municípios preservada (Spearman 0.69).


O modelo prevê o percentual de alfabetizados e o risco é a chance de ficar abaixo da meta. A meta entra no fim, não no aprendizado, e por isso o modelo sobrevive a mudanças na regra. O viés de -7 p.p. em 2025 é o salto nacional daquele ano, que nenhum modelo treinado em 2024 anteciparia: reajuste anual é parte do método.

Onde concentrar esforço em 2026

Indicador 2025 (% de alunos alfabetizados)



Risco de não atingir a meta de 2026



914


de 5.477 municípios com risco acima de 50% de não atingir a meta de 2026

UFs com mais municípios em risco

- RS** 69% dos municípios, salto mediano de 10 p.p.
- SP** 41% dos municípios, salto mediano de 2 p.p.
- RJ** 36% dos municípios, salto mediano de 3 p.p.
- RN** 28% dos municípios, salto mediano de 3 p.p.
- SC** 24% dos municípios, salto mediano de 1 p.p.

Lista completa por município, com os fatores de cada um, em reports/municipios_risco_2026.csv

Quais municípios se parecem




4 perfis

separados por dois eixos: fluxo e resultado; porte e renda.

Os perfis cortam as regiões: o Nordeste tem municípios nos quatro, e o perfil de renda baixa com resultado alto é 82% nordestino.

Cruzados com o risco, separam quem precisa de intervenção estrutural de quem só tem meta agressiva.

O que mais pesa na alfabetização



Nos dois modelos, em ordem:

1. % alfabetizados no ano anterior
2. IDEB anos iniciais (última edição)
3. UF (estado)
4. Participação na prova no ano anterior (%)
5. Salto necessário para a meta (p.p.)
6. População (Censo 2022)

SHAP e permutação concordam: histórico da rede, IDEB e presença vêm antes da renda. Redes bem geridas alfabetizam em contextos pobres.

Como isso apoia a decisão

1

Triagem anual

lista de municípios por risco de não atingir a meta, com os fatores de cada um, antes do ano letivo

2

Sinal de alerta barato

distorção idade-série, abandono e presença na prova: três números que já estão no Censo e antecipam o resultado

3

Estratégia por perfil

mesma intervenção para municípios do mesmo perfil, independente da região

4

Limites honestos

modelo preditivo, não causal; não prevê choques de política; precisa de reajuste a cada ciclo

FECHAMENTO

De dado público a decisão

Gold real, pipeline reproduzível, dois modelos validados no tempo, perfis de município e explicações em linguagem de gestão.

Próximos passos: variáveis do aluno e da escola (Censo Escolar por escola), avaliação causal de programas de alfabetização e reajuste anual automatizado com o dado novo.

 github.com/guillecosome/fiap-ai-scientist-tech-challenge-fase-03

Vídeo executivo (5 min): (link do vídeo)

Guilherme Cosme · RM 372204 · MBA AI Scientist · FIAP / POSTECH