

TECH CHALLENGE · FASE 3

Predição e Inteligência Analítica para Alfabetização no Brasil

Modelos preditivos sobre a camada Gold do Indicador Criança Alfabetizada

Guilherme Cosme

RM 372204 · Turma 1IAST · MBA AI Scientist · FIAP / POSTECH

 github.com/guillecosme/fiap-ai-scientist-tech-challenge-fase-03

Vídeo executivo (5 min): <https://www.loom.com/share/447ba58dab7f4fd8ae69ce14f2f96847>

CONTEXTO

Contexto e problema

O Indicador Criança Alfabetizada mede, a cada ano, o percentual de alunos do 2º ano que atingem o nível de leitura e escrita esperado, por município, com metas anuais até 2030.

O indicador é conhecido depois da prova. A gestão precisa saber antes quais municípios tendem a ficar abaixo da meta, quais fatores estão associados ao resultado e onde concentrar apoio.

Esta fase usa a camada Gold da Fase 2, agora com dado real do Inep e do IBGE, para treinar modelos que respondem a essas perguntas.

56% → 66%

crianças alfabetizadas no 2º ano, 2023 a 2025
(Brasil, rede pública)

80%

meta nacional para 2030, com metas anuais por
município

743

pontos na escala Saeb: o corte que define uma
criança alfabetizada

Base de dados

1

Indicador e metas

Inep: resultado por município
2023 a 2025 e metas anuais
até 2030

2

Microdados por aluno

4,3 milhões de alunos
avaliados em 2024 e 2025,
com rede, escola e
proficiência

3

Contexto educacional

Censo Escolar (docentes,
turmas, distorção),
rendimento, IDEB 2005 a
2025, INSE

4


Território e renda

IBGE: população, densidade,
PIB e composição da
economia

Mesmo contrato de esquema da Fase 2, tabelas recompostas com as fontes públicas e uma tabela nova no grão de aluno. Nenhuma fonte exige credencial; downloads conferidos por hash.

Alinhamento temporal: para prever o ano t só entram variáveis conhecidas antes da prova (Censo Escolar de t , rendimento e IDEB de $t-1$, resultado de $t-1$, meta de t).

Análise exploratória: principais achados



A UF explica um terço da variação entre municípios

a região explica 6%. Gestão estadual e instrumento de avaliação pesam mais do que geografia.

Fluxo escolar tem correlação maior que renda

abandono, reprovação e distorção idade-série: -0,35 a -0,39; INSE e PIB per capita: abaixo de 0,10.

85% da variância do alvo está dentro da escola

sem variáveis do aluno, o modelo ordena escolas e redes; não classifica crianças individualmente.

Pipeline de modelagem

1

Preprocessamento integrado

imputação pela mediana, log nas variáveis de porte e renda, escalonamento e one-hot, tudo dentro do pipeline e ajustado só no treino

2

Validação por município

folds que separam municípios inteiros; busca aleatória de hiperparâmetros em logística, random forest e gradient boosting

3

Teste temporal




treino em 2024, teste em 2025 aberto uma única vez; curvas de aprendizado e ablação por bloco de variáveis

4

Ponto de operação

limiar definido por um critério de política: recall mínimo de 70% da classe de risco

Modelo do aluno



0,65


AUC-ROC no teste de 2025, IC 95% 0,638 a 0,656 (validação 2024: 0,66)

69%

das crianças não alfabetizadas de 2025 identificadas no ponto de operação

Os microdados não trazem variáveis do aluno; o modelo usa contexto de escola e município. A variante sem as variáveis medidas no dia da prova, para triagem antecipada, fica em AUC 0,64.

Modelo de risco municipal



Classificador direto

AUC 0,81 em 2024 e 0,60 em 2025: a regra das metas mudou entre os anos e o classificador não generaliza.

Regressão do nível + meta

AUC do risco 0,77 em 2025 (IC 95% 0,758 a 0,785); ordem dos municípios preservada (Spearman 0,69).


Testes de robustez

Alvo embaralhado vai ao nível da média; ganho sobre a regra "quanto falta para a meta" de +0,029 de AUC, IC que não cruza zero; em estado nunca visto a ordem se mantém e o patamar erra.


O modelo prevê o percentual de alfabetizados; o risco é a probabilidade de ficar abaixo da meta, calculada com a distribuição dos resíduos. A meta entra depois do aprendizado, e a formulação se mantém quando a regra muda. O viés de -7 p.p. em 2025 corresponde ao aumento nacional daquele ano, não previsível a partir de 2024; é ele que infla o risco no backtest (Brier 0,243, contra 0,189 com o efeito ano) e entra na incerteza de 2026.

Projeção de risco para 2026

Indicador 2025 (% de alunos alfabetizados)



Risco de não atingir a meta de 2026



936

de 5.477 municípios com risco acima de 50% de não atingir a meta de 2026, já com a incerteza entre anos


UFs com mais municípios em risco

% dos municípios da UF e salto mediano até a meta

- RS** 70% em risco, salto de 10 p.p.
- SP** 42% em risco, salto de 2 p.p.
- RJ** 36% em risco, salto de 3 p.p.
- RN** 28% em risco, salto de 3 p.p.
- AM** 25% em risco, salto de 7 p.p.

No RS a meta foi ancorada no nível de 2023, anterior à queda de 2024: o risco alto mede a distância até a meta, não a condição das redes. Lista completa em [reports/municipios_risco_2026.csv](#).

Perfis de municípios



4 perfis

K-Means com K = 4, escolhido por cotovelo, silhueta e Davies-Bouldin; dois eixos no PCA: fluxo e resultado; porte e renda.


Os perfis cortam as regiões: o Nordeste tem municípios nos quatro, e o perfil de renda baixa com resultado alto é 82% nordestino.

Cruzados com o risco de 2026, separam municípios que precisam de intervenção estrutural de municípios com meta ambiciosa e rede consolidada.

Interpretabilidade: variáveis mais influentes



Fatores que mais impactam a alfabetização (importância SHAP média)



Modelo do município, em ordem:

- 1. % alfabetizados no ano anterior
- 2. IDEB anos iniciais (última edição)
- 3. UF (estado)
- 4. Participação na prova no ano anterior (%)
- 5. Salto necessário para a meta (p.p.)
- 6. População (Censo 2022)

No modelo do aluno o histórico da rede também vem primeiro; depois salto para a meta, presença na prova e IDEB. Nos dois, as variáveis de renda ficam atrás das que a gestão da rede acompanha.

Aplicação em políticas públicas

1

Triagem anual

lista de municípios por risco de não atingir a meta, com as variáveis de contexto de cada um, antes do ano letivo

2

Sinais de alerta antecipados

distorção idade-série, abandono e presença na prova estão disponíveis meses antes do indicador

3

Estratégia por perfil

mesma intervenção para municípios do mesmo perfil, independente da região

4

Limites

modelo preditivo, não causal; não antecipa choques; reajuste a cada ciclo; válido para os 27 estados do treino, não para transferir a outro contexto

FECHAMENTO

Conclusão

Gold recomposta com dado real, pipeline reproduzível, dois modelos validados em teste temporal, perfis de município e explicações com rótulos de negócio.

Próximos passos: variáveis do aluno e da escola (Censo Escolar por escola), avaliação causal de programas de alfabetização e reajuste anual automatizado com o dado novo.

 github.com/guillecosme/fiap-ai-scientist-tech-challenge-fase-03

Vídeo executivo (5 min): <https://www.loom.com/share/447ba58dab7f4fd8ae69ce14f2f96847>

Guilherme Cosme · RM 372204 · MBA AI Scientist · FIAP / POSTECH